
SPACE RISK IA

Global Solution de Inteligência Artificial & Machine Learning

Sistema Inteligente de Alerta com Dados Espaciais Simulados

Arthur Bobadilla Franchi - RM555056

Luan Orlandelli Ramos - RM554747

Jorge Luiz - RM554418

1. Resumo da Solução

O Space Risk IA é um protótipo de análise de risco ambiental construído em Python/scikit-learn que utiliza dados de sensoriamento remoto simulados para apoiar decisões de defesa civil, gestão ambiental e agricultura. A solução responde três perguntas estratégicas de forma automatizada:

- Qual é o índice estimado de impacto de uma região? → Regressão Linear Múltipla
- A região deve ser tratada como alto ou baixo risco? → Regressão Logística e Árvore de Decisão
- Quais regiões possuem perfis ambientais semelhantes? → Segmentação K-Means ($k = 4$)

2. Descrição do Dataset

O dataset contém 320 regiões monitoradas por sensores espaciais simulados, com 14 colunas distribuídas em features ambientais e dois targets:

Coluna	Tipo	Descrição
temperatura_media_c	Feature	Temperatura média da região (°C)
umidade_solo_pct	Feature	Umidade estimada do solo (%)
indice_vegetacao_ndvi	Feature	Índice de vegetação (0 a 1)
chuva_prevista_mm	Feature	Precipitação prevista (mm)
vento_kmh	Feature	Velocidade do vento (km/h)
historico_eventos_5anos	Feature	Eventos críticos nos últimos 5 anos
altitude_m	Feature	Altitude média da região (m)
inclinacao_terreno_graus	Feature	Inclinação média do terreno (°)
densidade_populacional_km2	Feature	Habitantes por km ²
proximidade_area_urbana_km	Feature	Distância até área urbana (km)
cobertura_nuvens_pct	Feature	Cobertura de nuvens (%)
indice_impacto	Target — Regressão	Índice contínuo de impacto (0–96,8)
risco_alto	Target — Classificação	Binário: 0 = baixo risco; 1 = alto risco
regiao_id	Identificador	ID administrativo — não usado em treino. Por ser um identificador arbitrário sem relação causal com as condições ambientais, seu uso introduziria um padrão nominal que não se generaliza para regiões novas, comprometendo a capacidade preditiva do modelo.

Distribuição do target de classificação: 200 regiões de alto risco (62,5%) e 120 de baixo risco (37,5%). Nenhum valor nulo foi identificado em nenhuma coluna.

3. Análise Exploratória e Correlação

O mapa de calor de Pearson revelou padrões consistentes entre as features e os dois targets. As principais correlações com `indice_impacto` foram:

- `historico_eventos_5anos`: $r = +0,78$ — maior correlação positiva; regiões com longo histórico de ocorrências acumulam impactos maiores.
- `indice_vegetacao_ndvi`: $r = -0,62$ — correlação negativa expressiva; vegetação densa atua como fator protetor.
- `vento_kmh`: $r = +0,50$ e `temperatura_media_c`: $r = +0,45$ — condições climáticas severas amplificam a vulnerabilidade.
- `umidade_solo_pct`: $r = -0,31$ — solos úmidos reduzem o risco de incêndios e eventos de seca.

Em relação ao segundo target (`risco_alto`), as correlações mais relevantes foram: `historico_eventos_5anos` ($r = +0,69$) e `vento_kmh` ($r = +0,45$) como fatores de elevação do risco; e `indice_vegetacao_ndvi` ($r = -0,51$) e `umidade_solo_pct` ($r = -0,38$) como fatores de proteção. A coerência entre os padrões de correlação dos dois targets reforça a consistência interna do dataset e valida as escolhas de features para os modelos supervisionados. Nota: correlação indica associação, não causalidade.

4. Regressão Linear Múltipla

Objetivo: prever a variável contínua `indice_impacto` a partir das 11 features ambientais. Divisão: 80% treino / 20% teste (`random_state=42`).

Métrica	Valor	Interpretação
R² (coef. de determinação)	0,9744	97,4% da variância explicada
MAE (erro médio absoluto)	3,23 pontos	~5,9% da média do target (54,6)
RMSE	3,99 pontos	Erro quadrático — ainda muito baixo

O coeficiente mais relevante foi `indice_vegetacao_ndvi` ($-36,5$): cada ponto a mais no NDVI reduz o índice de impacto em ~36 pontos. Em sentido oposto, `historico_eventos_5anos` ($+3,7$) é o maior fator de elevação do risco.

Interpretação do R^2 alto: um R^2 de 0,9744 indica que a relação entre as variáveis ambientais e o `indice_impacto` é predominantemente linear e estruturada. Em dados reais de satélite, esse valor tenderia a ser menor devido ao ruído, exigindo modelos não lineares ou regularização.

5. Regressão Logística

Objetivo: classificar risco_alto (0/1). A variável indice_impacto foi removida das features para evitar vazamento de dados. Pipeline: StandardScaler + LogisticRegression. Separação com estratificação (stratify=y).

Classe	Precision	Recall	F1-Score	Support	
Baixo Risco (0)	0,95	0,88	0,91	24	TN=21 FP=3
Alto Risco (1)	0,93	0,97	0,95	40	FN=1 TP=39
Acurácia geral	—	—	0,9375	64	93,75%

O modelo gerou apenas 1 falso negativo (FN) — alto risco classificado como baixo risco — e 3 falsos positivos (FP). Em sistemas de alerta, o FN é o erro mais perigoso pois omite o risco para populações vulneráveis. O predict_proba confirmou separação praticamente perfeita entre as classes: as 5 regiões com maior probabilidade de alto risco receberam $P(\text{risco_alto})$ entre 0,9991 e 0,9999 — todas com rótulo real = 1; e as 5 regiões mais seguras receberam $P(\text{risco_alto})$ entre 0,00002 e 0,00038 — todas com rótulo real = 0. Esse comportamento indica que o modelo não opera na zona de ambigüidade próxima a 0,5, e que ajustes de limiar de decisão poderiam ser feitos com controle preciso do trade-off entre FP e FN.

6. Árvore de Decisão

Mesmo X e y da Regressão Logística. Parâmetros: DecisionTreeClassifier(max_depth=4, random_state=42). Modelo gerou 14 folhas.

Métrica	Regressão Logística	Árvore de Decisão
Acurácia	93,75%	96,88% ✓
Precision — Alto Risco	0,93	0,97 ✓
Recall — Alto Risco	0,97	0,97
F1-Score — Alto Risco	0,95	0,97 ✓
Falsos Positivos (FP)	3	1 ✓
Falsos Negativos (FN)	1	1
Interpretabilidade	Moderada	Alta ✓

Regra mais relevante extraída via export_text: se historico_eventos_5anos > 3 e inclinacao_terreno_graus > 1° e indice_vegetacao_ndvi ≤ 0,68 → Alto Risco. A feature mais importante foi historico_eventos_5anos com 59,4% de importância Gini.

A Árvore de Decisão superou a Regressão Logística em todas as métricas e ainda oferece regras auditáveis em linguagem natural — tornando-a o modelo mais adequado para sistemas de alerta que exigem explicabilidade institucional.

7. Segmentação com K-Means (k = 4)

Features de entrada (8 variáveis ambientais — risco_alto excluído): temperatura_media_c, umidade_solo_pct, indice_vegetacao_ndvi, chuva_prevista_mm, vento_kmh, historico_eventos_5anos, inclinacao_terreno_graus, altitude_m. Padronização: StandardScaler. Resultado: 4 clusters com 80 regiões cada (25% cada).

Cluster	Nome	Temp. (°C)	Umidade (%)	NDVI	Risco Alto
0	Planícies úmidas com chuva intensa	26,97	77,87%	0,43	79%
1	Encostas elevadas e instáveis	24,95	60,38%	0,57	88% Δ
2	Regiões vegetadas e protegidas	23,25	66,72%	0,67	0% $\checkmark$
3	Regiões áridas e ventosas	35,58	20,67%	0,26	84%

O Cluster 2 (regiões vegetadas) foi o único grupo com risco_alto = 0%, validando o papel protetor da vegetação identificado na análise de correlação. O Cluster 1 (encostas elevadas) apresentou o maior risco — 88% — reflexo da combinação de altitude e inclinação que favorece deslizamentos.

8. Conclusão

8.1 Problema real enfrentado

O Space Risk IA apoia a gestão de riscos ambientais e a defesa civil em territórios extensos e de difícil acesso. Ao automatizar a estimativa de impacto, a classificação de risco e a segmentação de perfis territoriais, o sistema permite que equipes de resposta priorizem recursos com base em evidências — substituindo inspeções presenciais lentas por alertas baseados em dados de sensoriamento remoto.

8.2 Dados espaciais e de satélite

Cada variável do dataset tem um equivalente direto em fontes espaciais abertas: o NDVI é calculado pelo Sentinel-2 (ESA) e Landsat (NASA); a temperatura de superfície vem do sensor MODIS/VIIRS; a precipitação em tempo real é fornecida pela missão GPM (NASA/JAXA); a umidade do solo pelo satélite SMAP; e a altitude e inclinação pelos modelos digitais de elevação SRTM. Um pipeline de ingestão automática via APIs (Google Earth Engine, Copernicus, NASA Earthdata) tornaria o protótipo um sistema funcional com atualização contínua.

8.3 Conexão com os ODS

ODS 13 — Ação contra a mudança global do clima (principal): o sistema analisa variáveis diretamente impactadas pelas mudanças climáticas e apoia a adaptação de comunidades vulneráveis, alinhando-se à meta 13.3 de resiliência e capacidade adaptativa.

ODS 11 — Cidades e comunidades sustentáveis (principal): a inclusão de variáveis como `proximidade_area_urbana_km` e `densidade_populacional_km2` permite identificar zonas periurbanas críticas, contribuindo para a meta 11.5 de redução de mortes e perdas causadas por desastres.

ODS 9 — Indústria, inovação e infraestrutura: o protótipo demonstra como IA e dados espaciais podem ser democratizados para gerar impacto social. De forma específica, a combinação de regressão, classificação e segmentação em um único pipeline contribui diretamente para a meta 9.5 da ONU — que preconiza o fortalecimento da pesquisa científica, a melhoria das capacidades tecnológicas e o incentivo à inovação em países em desenvolvimento. Ao transformar dados de satélite em inteligência acionável com ferramentas abertas (Python, scikit-learn, Google Colab), o sistema exemplifica como infraestrutura tecnológica de baixo custo pode suportar decisões de alto impacto — modelo replicar por municípios e órgãos públicos sem investimento em hardware proprietário.

ODS 2 — Fome zero e agricultura sustentável: os clusters identificados (especialmente os perfis árido e vegetado) podem orientar alertas a produtores rurais sobre perda de umidade, queda do NDVI e precipitação extrema.

8.4 Modelo mais útil para o protótipo

A Árvore de Decisão foi o modelo mais útil para este contexto, por três razões convergentes: (1) desempenho superior — acurácia de 96,88% contra 93,75% da Regressão Logística, com apenas 1 FP e 1 FN; (2) interpretabilidade — regras auditáveis em linguagem natural, essenciais para sistemas de alerta que precisam de validação institucional; (3) governança — facilita auditoria, detecção de vieses e manutenção ao longo do tempo. A Regressão Linear foi indispensável para medir a intensidade do risco, e o K-Means revelou estruturas territoriais invisíveis aos classificadores supervisionados. A solução completa é o conjunto dos três.

8.5 Melhorias futuras

- Substituição dos dados simulados por dados reais de satélite via APIs do Google Earth Engine, NASA Earthdata e Copernicus.
 - Ajuste do limiar de decisão (abaixo de 0,5) para minimizar falsos negativos em contextos de alta criticidade.
 - Implementação de Random Forest ou XGBoost para maior robustez com dados ruidosos.
 - Validação cruzada estratificada (k-fold) para estimativas de desempenho mais confiáveis.
 - Painel de monitoramento interativo georreferenciado com Folium ou Streamlit para uso por gestores não técnicos.
 - Modelagem temporal com séries históricas para capturar sazonalidade e tendências de degradação ambiental.
-